

Covariance, corrélation, régression linéaire

1 Définition et propriétés

1.1 Variance

La variance d'une variable aléatoire X est une **mesure de sa dispersion** autour de sa moyenne $\mathbb{E}[X]$.

Définition 1 (Variance)

La variance d'une v.a. X s'écrit :

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

(sous réserve de convergence.)

Proposition 2 (Propriétés)

1. On a la **formule de Kœnig-Huygens** :

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

2. Pour $a, b \in \mathbb{R}$ constantes déterministes, on a : $\text{Var}(aX + b) = a^2 \cdot \text{Var}(X)$.

3. $[\text{Var}(X) = 0] \iff [X \text{ déterministe}]$.

(et alors : $X \equiv \mathbb{E}[X]$.)

1.2 Covariance

La covariance est une **mesure de la co-dispersion** d'un couple de v.a. (X, Y) .

Définition 3 (Covariance)

La covariance de deux v.a. X, Y s'écrit :

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X]) \cdot (Y - \mathbb{E}[Y])]$$

(sous réserve de convergence.)

Proposition 4 (Kœnig-Huygens)

Soient X, Y deux variables aléatoires.

Alors :

$$\text{Cov}(X, Y) = \mathbb{E}[X \cdot Y] - \mathbb{E}[X] \cdot \mathbb{E}[Y]$$

(sous réserve de convergence)

Des variables indépendantes sont **décorrélées** :

Proposition 5 (Cas de l'indépendance)

Si X et Y sont **indépendantes**, alors :

$$\text{Cov}(X, Y) = 0.$$

Proposition 6 (Propriétés)

La covariance vérifie :

► **Symétrie** $\text{Cov}(Y, X) = \text{Cov}(X, Y)$.

► **Variance** $\text{Cov}(X, X) = \text{Var}(X)$

Distributivité dans la covariance

La covariance est **bilinéaire** :

$$\text{Cov}(X, Y) = \mathbb{E} \left[\underbrace{\left(\overbrace{X - \mathbb{E}[X]}^{\text{linéaire en } X} \right) \cdot \left(\overbrace{Y - \mathbb{E}[Y]}^{\text{linéaire en } Y} \right)}_{\text{bilinéaire en } (X, Y)} \right]$$

Ainsi, l'expression $\text{Cov}(\lambda_1 X_1 + \lambda_2 X_2, \mu_1 Y_1 + \mu_2 Y_2)$ se développe par **double distributivité**.

On a donc les « mêmes règles de calcul » pour $\text{Cov}(X, Y)$ que pour xy où $x, y \in \mathbb{R}$:

► Formules Var, Cov

$$\text{Var}(X + Y) = \text{Var}(X) + 2 \text{Cov}(X, Y) + \text{Var}(Y)$$

$$\text{Var}(X - Y) = \text{Var}(X) - 2 \text{Cov}(X, Y) + \text{Var}(Y)$$

$$\text{Cov}(X + Y, X - Y) = \text{Var}(X) - \text{Var}(Y)$$

$$\text{Var}(Y - aX) = \text{Var}(Y) - 2a \text{Cov}(X, Y) + a^2 \text{Var}(X)$$

► Formules de polarisation

$$\text{Cov}(X, Y) = \frac{1}{2} \cdot [\text{Var}(X + Y) - \text{Var}(X) - \text{Var}(Y)]$$

$$\text{Cov}(X, Y) = \frac{1}{4} \cdot [\text{Var}(X + Y) - \text{Var}(X - Y)]$$

► Homologues numériques

$$(x + y)^2 = x^2 + 2xy + y^2$$

$$(x - y)^2 = x^2 - 2xy + y^2$$

$$(x + y)(x - y) = x^2 - y^2$$

$$(y - ax)^2 = y^2 - 2axy + a^2x^2$$

$$xy = \frac{1}{2} \cdot [(x + y)^2 - x^2 - y^2]$$

$$xy = \frac{1}{4} \cdot [(x + y)^2 - (x - y)^2]$$

2 L'encadrement de Cauchy-Schwarz

Proposition 7 (Pour la covariance)

Soient X, Y deux variables aléatoires.

On note σ_X, σ_Y leurs écarts-type.

$$(\sigma_X = \sqrt{\text{Var}(X)}, \sigma_Y = \sqrt{\text{Var}(Y)})$$

Alors :

$$-\sigma_X \cdot \sigma_Y \leq \text{Cov}(X, Y) \leq \sigma_X \cdot \sigma_Y$$

Définition 8 (Corrélation)

On appelle **corrél**ation de X et Y :

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \cdot \sigma_Y}$$

(ou **coefficient de corrélation linéaire**)

Par la Proposition 7, on a donc :

$$\rho(X, Y) \in [-1; 1].$$

Démonstration de l'encadrement (Prop. 7) :

On considère la fonction $T : \begin{cases} \mathbb{R} \rightarrow \mathbb{R} \\ a \mapsto \text{Var}(Y - aX). \end{cases}$

- **Signe de T** La variance d'une variable aléatoire $\text{Var}(Z) = \mathbb{E} \left[\underbrace{(Z - \mathbb{E}[Z])^2}_{\geq 0} \right] \geq 0$.
Ainsi, on a $\forall a \in \mathbb{R}, T(a) \geq 0$.

- **T est un trinôme**

$$\begin{aligned} \text{On développe par double distributivité : } T(a) &= \text{Var}(Y - aX) \quad (\text{bilinéarité puis symétrie}) \\ &= \text{Var}(Y) - 2a \cdot \text{Cov}(X, Y) + a^2 \cdot \text{Var}(X) \end{aligned}$$

$$\text{On reconnaît un trinôme : } T(a) = r + qa + pa^2.$$

- **Discriminant**

$$\text{Calculons le discriminant du trinôme : } T(a) = \text{Var}(X) \cdot a^2 - 2 \cdot \text{Cov}(X, Y) \cdot a + \text{Var}(Y).$$

$$\begin{aligned} \text{On trouve : } \Delta &= [-2 \text{Cov}(X, Y)]^2 - 4 \text{Var}(X) \cdot \text{Var}(Y) \\ &= 4 [\text{Cov}(X, Y)^2 - \text{Var}(X) \cdot \text{Var}(Y)] \end{aligned}$$

- **Conclusion** Le trinôme T ne change pas de signe. Son discriminant Δ est donc ≤ 0 .

$$\text{Il vient : } \text{Cov}(X, Y)^2 - \text{Var}(X) \cdot \text{Var}(Y) \leq 0, \quad \text{soit : } \text{Cov}(X, Y)^2 \leq \text{Var}(X) \cdot \text{Var}(Y).$$

L'inéquation $u^2 \leq v$

$$\left| \text{Pour } v \geq 0, \text{ on résout l'inéquation : } [u^2 \leq v] \iff [-\sqrt{v} \leq u \leq \sqrt{v}] \right|$$

$$\text{On en déduit bien : } -\sqrt{\text{Var}(X) \cdot \text{Var}(Y)} \leq \text{Cov}(X, Y) \leq \sqrt{\text{Var}(X) \cdot \text{Var}(Y)}$$

$$\text{soit : } -\sigma_X \cdot \sigma_Y \leq \text{Cov}(X, Y) \leq \sigma_X \cdot \sigma_Y$$

■

3 Régression linéaire

Soient deux variables aléatoires X et Y .

On suppose que : ► la valeur de X est **connue**, (X est la **variable explicative**)

► la valeur de Y **inconnue**, et à **estimer**. (Y est la **variable expliquée**)

On recherche une estimation de Y en fonction de X , estimation **aussi bonne que possible**.

- **Forme de l'estimation : ajustement affine**

Plus précisément, on cherche à estimer Y par une expression affine $\hat{Y} = aX + b$. où a, b des constantes déterministes.

- **Résidu de l'estimation**

C'est la variable aléatoire ϵ définie comme « l'erreur » : $\epsilon = Y - \hat{Y}$. (soit $Y = \hat{Y} + \epsilon$)

- **Optimisation au sens des moindres carrés**

On cherche le couple (a, b) tel que $\hat{Y} = aX + b$ minimise l'**erreur quadratique** (moyenne) :

$$r(a, b) = \mathbb{E}[\epsilon^2] = \mathbb{E}[(Y - \hat{Y})^2]$$

Proposition 9 (Régression linéaire)

1. L'optimisation des moindres carrés de l'estimation de Y par $\hat{Y} = aX + b$ est réalisée par un unique couple (a, b) de réels déterministes.
2. Pour cette valeur optimale de (a, b) le résidu $\epsilon = Y - \hat{Y}$ vérifie :
 - ▶ le résidu ϵ est nul en moyenne (\hat{Y} **non-biaisé**) : $\mathbb{E}[\epsilon] = 0$,
 - ▶ le résidu ϵ et X sont décorrélés : $\text{Cov}(X, \epsilon) = 0$.

De plus le coefficient directeur a est du signe de $\text{Cov}(X, Y)$. (sens de la tendance)
3. Si $\rho(X, Y) = \pm 1$, alors, pour cette valeur de (a, b) , on a $Y = \hat{Y}$. (avec probabilité 1)

Remarques

1. Cette proposition précise le sens en lequel la covariance $\text{Cov}(X, Y)$ est une mesure de codispersion. Par exemple, elle donne le signe du coefficient directeur.
 - ▶ si $\text{Cov}(X, Y) > 0$, les variables X et Y varient « plutôt ensemble, » (*dans le même sens*)
 - ▶ si $\text{Cov}(X, Y) < 0$, les variables X et Y varient « plutôt en sens opposé »
2. L'ajustement affine $\hat{Y} = aX + b$ et le résidu $\epsilon = Y - \hat{Y}$ étant décorrélés, leurs variances s'additionnent :

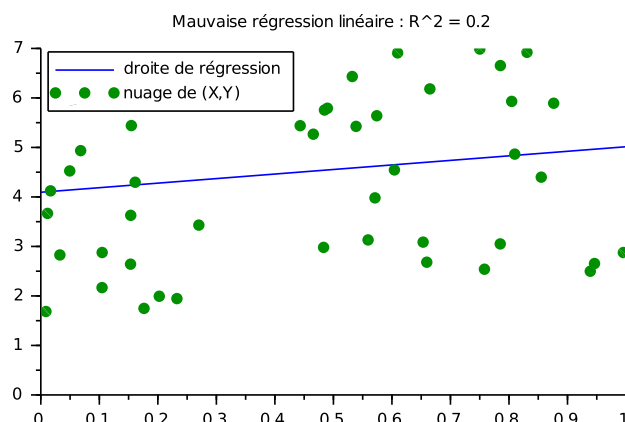

$$\text{Var}\left(\underbrace{\hat{Y} + \epsilon}_Y\right) = \text{Var}(\hat{Y}) + \text{Var}(\epsilon)$$

Ainsi on a : $\frac{\text{Var}(\hat{Y})}{\text{Var}(Y)} + \frac{\text{Var}(\epsilon)}{\text{Var}(Y)} = 1$, et on dit que :

- ▶ $\frac{\text{Var}(\hat{Y})}{\text{Var}(Y)} = \rho(X, Y)^2$ est la part de variance expliquée, (ou **coeff^{nt} de détermination**, noté R^2)
- ▶ $\frac{\text{Var}(\epsilon)}{\text{Var}(Y)}$ est la part de variance inexpliquée

On a toujours $0 \leq R^2 \leq 1$, et R^2 indique la pertinence de la régression linéaire de Y par X .

- ▶ si le coeff^{nt} de détermination est **élevé** $R^2 \approx 1$, alors X explique bien Y .
- ▶ si le coeff^{nt} de détermination est **faible** $R^2 \approx 0$, l'explicabilité linéaire de Y par X est faible.

Interprétation graphique de la qualité de la régression linéaire :

Lemme 10 (Décomposition biais-variance)

1. L'erreur quadratique se décompose : $r(a, b) = \underbrace{\left(\mathbb{E}[Y - aX - b]\right)^2}_{\mathbb{E}[\epsilon]^2} + \underbrace{\text{Var}(Y - aX)}_{T(a)}.$
2. Le trinôme T est minimisé pour $a = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}.$
3. Le terme $\mathbb{E}[\epsilon]^2$ est minimisé pour $b = \mathbb{E}[Y] - a \cdot \mathbb{E}[X].$

Démonstration du Lemme 10 :

1. La décomposition biais-variance est une réécriture de la formule de Kœnig-Huygens.
2. Le carré $\mathbb{E}[\epsilon]^2 = \left(\mathbb{E}[Y - aX - b]\right)^2$ est minimisé quand $\mathbb{E}[Y - aX - b] = 0$, soit, en développant, pour $b = \mathbb{E}[Y] - a \cdot \mathbb{E}[X].$
3. On a étudié le trinôme $T(a) = \text{Var}(Y - aX) = \text{Var}(Y) - 2a \cdot \text{Cov}(X, Y) + a^2 \cdot \text{Var}(X).$
Il est minimisé quand $T'(a) = -2 \text{Cov}(X, Y) + 2 \text{Var}(X) \cdot a = 0$, soit $a = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}.$ ■

Démonstration de la Proposition 9 :

1. On vérifie que minimiser $r(a, b)$, c'est minimiser les deux termes de la décomposition :

$$r(a, b) = \left(\mathbb{E}[Y - aX - b]\right)^2 + \text{Var}(Y - aX)$$

et que la minimisation de $r(a, b)$ se réalise donc uniquement pour $\begin{cases} a = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} \\ b = \mathbb{E}[Y] - a \cdot \mathbb{E}[X] \end{cases}$

On trouve donc l'ajustement affine optimal :

$$\hat{Y} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} \cdot (X - \mathbb{E}[X]) + \mathbb{E}[Y].$$

2.
 - ▶ On vérifie que $\mathbb{E}[\hat{Y}] = \mathbb{E}[Y]$ et donc que $\mathbb{E}[\epsilon] = 0.$
 - ▶ On a : $T'(a) = -2 \text{Cov}(X, Y) + 2 \text{Var}(X) \cdot a = -2 \text{Cov}(X, Y - aX).$
Ainsi pour $T'(a) = 0$, il vient : $\text{Cov}(X, \underbrace{Y - aX}_{\epsilon + b}) = 0$, d'où $\text{Cov}(X, \epsilon) = 0.$
3. Si $\rho(X, Y) = \pm 1$, alors, d'après la Remarque 2., on trouve $\text{Var}(\epsilon) = 0.$
Par la Proposition 2-3., la variable ϵ est donc déterministe et $\epsilon \equiv \mathbb{E}[\epsilon] = 0.$
Ainsi, on a bien $Y - \hat{Y} \equiv 0$, soit : $Y \equiv \hat{Y} = aX + b.$ ■